RELATÓRIO EXPLORATÓRIO DO PROJETO

TEMA: Análise de Incidentes de IA em Serviços Financeiros: Viés Algorítmico, Risco Operacional e Respostas de Governança em Bancos e Fintechs

1. Objetivo do Projeto

1.1 Objetivo Geral

Neste projeto, meu objetivo é avaliar, com base em dados estruturados de incidentes de sistemas de inteligência artificial no setor financeiro, se há padrões sistemáticos de viés algorítmico, risco operacional e falhas de governança em aplicações de IA em bancos e fintechs. Para isso, utilizarei um banco de dados relacional, análises estatísticas e modelos de IA/ML, de forma a gerar evidências que possam apoiar a tomada de decisão em políticas de ética, gestão de risco e governança de IA no mercado financeiro.sciencedirect+2

1.2 Objetivos Específicos

De forma mais detalhada, busco:

- Identificar e quantificar incidentes documentados de IA no setor financeiro, com foco em credit scoring, detecção de fraude, trading algorítmico e automação bancária.intuition+2
- Analisar a severidade dos impactos causados (perdas financeiras, danos reputacionais, exclusão de clientes) e como esses impactos se distribuem entre diferentes segmentos de clientes.oxfordeconomics+1
- Avaliar quais respostas de governança (investigações regulatórias, sanções, mudanças de política) foram adotadas frente aos incidentes reportados.oxfordeconomics+1
- Construir modelos preditivos simples para estimar risco e severidade de futuros incidentes em instituições financeiras.github+1
- Desenvolver uma API RESTful que exponha os dados e as análises de maneira acessível para gestores de risco, reguladores e tomadores de decisão.1 Briefing

1.3 Questões de Pesquisa

As principais questões de pesquisa que pretendo investigar são:

1. Existe concentração de incidentes de IA em determinados tipos de aplicação financeira (crédito, fraude, trading)?onlinedegrees.sandiego+1
2. Incidentes envolvendo viés algorítmico em credit scoring afetam desproporcionalmente certos segmentos de clientes (pequenas empresas, minorias, regiões específicas)?linkedin+1
3. Incidentes de maior severidade (perdas financeiras significativas, falhas sistêmicas) resultam em ações regulatórias proporcionais?sciencedirect+1
4. É possível identificar tendências temporais que indiquem aumento ou redução de incidentes ao longo do tempo, correlacionadas com evolução regulatória?fsb+1

2. Dados Utilizados e Preparação

2.1 Fonte de Dados

Os dados que utilizo neste trabalho vêm do **Artificial Intelligence Incident Database (AIID)**, um repositório que reúne incidentes documentados de sistemas de IA que causaram ou quase causaram danos em contextos reais. Para facilitar o uso em análise de dados, eu acesso esses incidentes na forma tabular por meio do dataset **"AI incident database"** disponível no Kaggle.partnershiponai+2

O AIID é construído a partir de fontes como notícias financeiras (incluindo Bloomberg, Financial Times, Reuters), relatórios regulatórios, decisões judiciais e artigos acadêmicos, mas essas informações já aparecem no meu projeto em formato de tabela, com identificadores, datas, localizações, descrições resumidas, categorias de aplicação e tipos de dano associados a cada incidente.kaggle+3

Fontes complementares de análise incluem reportagens da Bloomberg sobre viés em modelos de IA aplicados a finanças e recursos humanos, que fornecem contexto adicional sobre a natureza dos incidentes.linkedin+1

Na prática, eu posso obter os dados de duas formas equivalentes:

- Fazendo o download do dataset no Kaggle: https://www.kaggle.com/datasets/konradb/ai-incident-databasekaggle
- Baixando a base diretamente pelo site do AIID: https://incidentdatabase.aiincidentdatabase

Para o projeto, considero as duas formas como equivalentes, pois ambas representam a mesma base de incidentes estruturados em formato tabular.incidentdatabase+1

2.2 Processo de Preparação

Depois de baixar o arquivo CSV, eu carrego a base em um ambiente Python (Google Colab) utilizando a biblioteca pandas. Nessa etapa inicial, faço uma inspeção das colunas (df.columns), dos tipos de dados e de algumas linhas de exemplo (df.head()), para entender a estrutura do dataset.kaggle

A partir da base original, seleciono principalmente as seguintes colunas brutas, que são relevantes para o escopo do trabalho:arxiv+1

- incident_id – identificador único do incidente
- title / headline – título ou manchete do incidente
- summary – resumo textual do ocorrido
- occurred_date – data de ocorrência do incidente
- country / location – país ou região em que o incidente ocorreu
- sector / application – setor ou aplicação (foco em **finance, banking, financial services**)
- technology – nome ou tipo da tecnologia de IA envolvida
- harm_type / issue – tipo principal de dano (fairness, safety, financial loss, etc.)
- severity – nível de severidade do incidente, quando disponívelarxiv+1

Em seguida, realizo etapas de limpeza, como padronização de formatos de data, normalização de nomes de países e setores, e tratamento de valores ausentes sempre que necessário.

2.3 Filtragem Temática e Enriquecimento

Como o foco do meu projeto é o **setor financeiro**, eu aplico filtros nas categorias e descrições dos incidentes, procurando por termos como:

- "finance", "financial services", "banking", "fintech"
- "credit scoring", "loan approval", "credit decision"
- "fraud detection", "anti-money laundering", "AML"
- "algorithmic trading", "high-frequency trading", "robo-advisor"
- "automated underwriting", "risk assessment"credgenics+1

Esses filtros permitem isolar um subconjunto de incidentes que estão diretamente relacionados ao tema, ou seja, situações em que sistemas de IA foram usados em contextos bancários, de crédito, detecção de fraude, investimentos ou outros serviços financeiros.intuition+2
A partir desse subconjunto, crio um conjunto de **variáveis derivadas** (explicadas na próxima seção) que codificam de forma estruturada informações sobre tipo de aplicação financeira, segmento de cliente afetado, tipo de incidente, severidade do impacto financeiro e respostas de governança.arxiv+1
Por fim, eu armazeno as variáveis estruturadas em um **banco de dados relacional SQLite**, com múltiplas tabelas inter-relacionadas, como uma tabela principal de incidentes, uma tabela de impactos financeiros e uma tabela de respostas regulatórias. Esse banco serve como base única tanto para as análises estatísticas quanto para os modelos de IA/ML e para a API RESTful que desenvolvo sobre ele.drlee+11_Briefing.pdf

3. Variáveis do Estudo

3.1 Variáveis Brutas (Extraídas do Dataset)

As principais variáveis brutas que seleciono da base AIID/Kaggle são:
- incident_id (numérica): identificador único do incidente
- title (texto): título ou manchete que descreve o incidente
- summary (texto): resumo descritivo do ocorrido
- occurred_date (data): data de ocorrência do incidente
- country (categórica): país onde o incidente ocorreu
- sector (categórica): setor de aplicação (foco em **finance, banking, financial services**)
- technology (texto): tipo de tecnologia de IA usada
- harm_type (categórica): tipo principal de dano (fairness, financial loss, privacy, safety, etc.)arxiv+1
- severity (categórica/numérica): nível de severidade do incidente, quando informado

Essas variáveis são a matéria-prima a partir da qual construo variáveis analíticas específicas para o meu problema de

3.2 Variáveis Derivadas (Criadas para Análise)

3.2.1 Tipo de Aplicação Financeira

- **application_type (categórica)**
  Classifica o tipo de aplicação de IA no contexto financeiro:onlinedegrees.sandiego+1
  - credit_scoring – sistemas de avaliação de crédito e aprovação de empréstimos
  - fraud_detection – detecção de fraude e lavagem de dinheiro (AML)
  - algorithmic_trading – trading algorítmico e high-frequency trading
  - robo_advisor – consultoria de investimentos automatizada
  - risk_assessment – avaliação de risco de portfólio e subscrição automatizada
  - customer_service – chatbots e automação de atendimento
- **Por que importa:** Permite identificar quais aplicações de IA em finanças apresentam mais incidentes e riscos.credgenics+1

3.2.2 Segmento de Cliente Afetado

- **customer_segment (categórica)**
  Identifica qual segmento de cliente foi principalmente afetado:l
  - retail – clientes pessoa física (varejo)

  - sme – pequenas e médias empresas
  - corporate – grandes corporações
  - underserved – grupos sub-atendidos/minorias
  - general – impacto sistêmico geral
- **Por que importa:** Essencial para avaliar se há viés algorítmico afetando desproporcionalmente certos segmentos, especialmente grupos vulneráveis.intuition+1

3.2.3 Tipo de Incidente

- **incident_type (categórica)**
  Classifica a natureza do problema
  - algorithmic_bias – viés sistemático em decisões automatizadas (ex: discriminação em aprovação de crédito)
  - operational_failure – falha técnica causando perdas ou interrupção de serviço
  - market_disruption – erro de trading algorítmico causando volatilidade ou flash crash
  - data_breach – vazamento de dados por falha de sistema de IA
  - regulatory_violation – violação de normas regulatórias por sistema automatizado
- **Por que importa:** Organiza os incidentes em categorias de risco operacional reconhecidas no setor financeiro.oxfordeconomics+1

3.2.4 Severidade do Impacto

- **severity_level (ordinal: baixa, média, alta, crítica)**
  A partir da variável original de severidade e análise dos resumos, classifico cada incidente:sciencedirect+1
  - **Crítica:** perdas financeiras >$10M, falha sistêmica afetando mercados, múltiplas violações regulatórias
  - **Alta:** perdas $1M-$10M, impacto reputacional significativo, investigação regulatória formal
  - **Média:** perdas $100K-$1M, reclamações de clientes, revisão interna obrigatória
  - **Baixa:** perdas <$100K, impacto limitado, correção imediata sem consequências externas
- **Por que importa:** Conecta diretamente com gestão de risco operacional e cálculo de capital regulatório (Basel).oxfordeconomics+1
- **financial_loss_amount (numérica)**
  Valor estimado de perda financeira direta em USD, quando reportado. **Por que importa:** Métrica quantitativa essencial para análise de risco financeiro.sciencedirect

3.2.5 Respostas de Governança e Regulatórias

Crio variáveis binárias para capturar respostas institucionais e regulatórias:

- **regulatory_investigation (0/1):** investigação formal por autoridade reguladora (SEC, FED, BACEN, etc.)
- **fine_imposed (0/1):** aplicação de multa ou sanção financeira
- **policy_change (0/1):** mudança declarada de política ou procedimento interno
- **system_suspended (0/1):** suspensão temporária ou permanente do sistema de IA
- **third_party_audit (0/1):** auditoria independente solicitada ou realizada **Por que importam:** Avaliam efetividade da governança e resposta regulatória proporcional ao risco.fsb+1

3.2.6 Dimensões Temporal e Geográfica

- **year (numérica):** ano de ocorrência do incidente
- **country_region (categórica):** região geográfica (América do Norte, Europa, Ásia-Pacífico, América Latina, etc.)oxfordeconomics
- **regulatory_regime (categórica):** regime regulatório predominante (EUA, UE/GDPR+MiCA, Ásia, Brasil, etc.) **Por que importam:** Permitem avaliar tendências temporais e comparar eficácia de diferentes marcos regulatórios.fsb+1

3.3 Por Que Essas Variáveis Ajudam na Tomada de Decisão

Com esse conjunto de variáveis, consigo responder questões diretamente úteis para tomada de decisão em gestão de risco e governança de IA no setor financeiro:

Para reguladores e supervisores bancários:
- Quais aplicações de IA apresentam maior risco operacional e requerem supervisão intensificada
- Há evidência de viés algorítmico sistemático que justifique novas diretrizes regulatória
- Os regimes regulatórios atuais são efetivos em prevenir/mitigar incidentes?oxfordeconomics

Para gestores de risco em bancos e fintechs:
- Quais tipos de incidentes resultam em maiores perdas financeiras?sciencedirect
- Quais segmentos de clientes apresentam maior risco de exposição a viés algorítmico?intuition
- Como priorizar investimentos em governança de IA e controles internos?oxfordeconomics+1

Para investidores e analistas:
- Incidentes de IA impactam significativamente o valor de mercado de instituições financeiras? ideas.repec+1
- Quais instituições demonstram melhor gestão de risco de IA?sciencedirect

Assim, as variáveis são escolhidas por sua relevância em produzir evidências para decisões concretas sobre gestão de risco e uso responsável de IA em finanças.

4. Hipóteses e Análise Estatística

4.1 Hipótese 1 – Concentração de Incidentes por Tipo de Aplicação

- **H_0 (hipótese nula):** a distribuição de incidentes é uniforme entre os diferentes tipos de aplicação de IA em finanças.
- **H_1 (hipótese alternativa):** certas aplicações (ex: credit scoring, algorithmic trading) apresentam concentração significativamente maior de incidentes.onlinedegrees.sandiego+1

Técnica: Teste qui-quadrado de aderência comparando distribuição observada com distribuição uniforme esperada.arxiv

Interpretação: Identificação de aplicações de alto risco que requerem controles mais rigorosos.

4.2 Hipótese 2 – Viés por Segmento de Cliente

- **H_0:** a proporção de incidentes envolvendo viés algorítmico é independente do segmento de cliente afetado.
- **H_1:** certos segmentos (ex: SME, underserved) são desproporcionalmente afetados por viés algorítmico em decisões de crédito.linkedin+1

Técnica: Teste qui-quadrado de independência entre incident_type (filtrando algorithmic_bias) e customer_segment.arxiv

Interpretação: Evidência de discriminação algorítmica que pode violar regulações de fair lending.

4.3 Hipótese 3 – Severidade e Resposta Regulatória

- **H_0:** a probabilidade de investigação regulatória é independente da severidade do incidente.
- **H_1:** incidentes de alta severidade (especialmente com perdas financeiras elevadas) resultam em maior probabilidade de investigação e sanções.oxfordeconomics

Técnica: Teste qui-quadrado entre severity_level e regulatory_investigation; regressão logística de regulatory_investigation em função de financial_loss_amount.arxiv+1
Interpretação: Avaliação da proporcionalidade e efetividade da supervisão regulatória.

4.4 Hipótese 4 – Tendência Temporal e Evolução Regulatória

- **H_0:** não há tendência temporal significativa no número de incidentes ao longo dos anos.
- **H_1:** existe tendência crescente ou decrescente correlacionada com marcos regulatórios (ex: implementação de GDPR, MiCA, AI Act na Europa; regulação do BACEN no Brasil).fsb+1

Técnica: Regressão linear de contagem anual de incidentes; teste de Mann-Kendall para tendência; análise de séries temporais interrompidas para avaliar impacto de marcos regulatórios.github+1
Interpretação: Efetividade de intervenções regulatórias em reduzir incidentes.

5. Técnicas de IA/ML e Estatística

5.1 Modelos de Machine Learning

5.1.1 Predição de Severidade e Perda Financeira

Variável alvo:
- severity_level (classificação multiclasse ou binária: baixa/média vs. alta/crítica)
- financial_loss_amount (regressão, para incidentes com perdas reportadas)

Features preditoras:
- application_type
- customer_segment
- incident_type
- country_region
- regulatory_regime
- year

Modelos candidatos:
1. **Random Forest Classifier/Regressor**
   - Vantagem: Robusto, lida bem com variáveis categóricas, feature importance interpretável
   - Uso: Predição de severidade e estimativa de perda financeiragithub
1. **XGBoost**
   - Vantagem: Alto desempenho, especialmente para dados tabulares
   - Uso: Benchmark de performancegithub
1. **Regressão Logística** (para severidade binária)
   - Vantagem: Interpretabilidade via coeficientes (odds ratios)
   - Uso: Explicação de fatores de risco para stakeholders não-técnicos

Métricas de avaliação:
- Classificação: Accuracy, Precision, Recall, F1-Score, ROC-AUC

- Regressão: RMSE, MAE, R^2
- Feature importance para identificar principais fatores de risco

5.1.2 Detecção de Padrões de Risco (Clustering - Opcional)

Objetivo: Identificar grupos de incidentes com características similares para tipologia de risco.
Técnica: K-Means ou DBSCAN sobre features numéricas e categóricas codificadas.
Uso: Criação de taxonomia de risco operacional de IA em finanças.oxfordeconomics+1

5.1.3 Análise de Texto (NLP Leve)

Objetivo: Classificar automaticamente incident_type ou application_type a partir do texto de summary.
Abordagem:
- Vetorização TF-IDF do resumo
- Classificadores: Logistic Regression, SVM, ou Naive Bayessimonmylius+1

Uso: Automatizar categorização de novos incidentes reportados.

5.2 Técnicas Estatísticas

Análise Descritiva:
- Contagens, proporções, médias de perdas financeiras
- Distribuições por tipo de aplicação, segmento, região, ano

Análise Bivariada:
- Tabelas de contingência: application_type × severity_level, customer_segment × incident_typearxiv
- Correlação entre financial_loss_amount e outras variáveis numéricas

Inferência Estatística:
- Testes qui-quadrado (independência e aderência)
- ANOVA/Kruskal-Wallis para comparar perdas médias entre grupos
- Intervalos de confiança (95%) para proporções
- Regressão linear/logística para modelar relações causais

5.3 Visualizações

- Gráficos de barras: distribuições por aplicação, segmento, tipo de incidente
- Boxplots: distribuição de perdas financeiras por severidade
- Séries temporais: evolução anual de incidentes com marcos regulatórios anotados
- Mapas coropleth: distribuição geográfica de incidentes
- Heatmaps: tabelas de contingência
- Sunburst/Treemap: hierarquia de incidentes (região → aplicação → tipo)

6. Estrutura do Projeto em Três Fases

Fase 1 – Exploratória e Construção da Base (Semanas 1-2)

Atividades:

1. **Coleta e estruturação**
   - Download do dataset AIID (Kaggle ou site oficial)incidentdatabase+1
   - Carga e inspeção inicial no Google Colab (pandas)
   - Identificação de colunas relevantes
1. **Limpeza e filtragem temática**
   - Filtrar incidentes do setor financeiro (sector == 'finance' ou termos relacionados)
   - Padronização de datas, países, categorias
   - Tratamento de valores ausenteskaggle+1
1. **Criação de variáveis derivadas**
   - Codificação de application_type, customer_segment, incident_type, severity_level
   - Extração de financial_loss_amount quando disponível
   - Classificação de regulatory_regime por país

1. **Construção do banco SQLite**
   - Tabela incidents (dados principais)
   - Tabela financial_impacts (perdas, custos, multas)
   - Tabela regulatory_responses (investigações, sanções, auditorias)
   - Definição de chaves primárias/estrangeirasmohamadrazzimy.hashnode+1

Entregáveis:
- Notebook Colab documentado com ETL completo
- Banco SQLite populado (ai_finance_incidents.db)
- Dicionário de dados detalhado

Fase 2 – Análises Ricas e Testes de Hipóteses (Semanas 3-4)

Atividades:
1. **Análise descritiva**
   - Estatísticas descritivas por variável
   - Distribuições univariadas
   - Identificação de outliers (perdas financeiras extremas)
1. **Análise bivariada e multivariada**
   - Tabelas de contingência (crosstabs)
   - Correlações
   - Visualizações comparativasoxfordeconomics
1. **Testes de hipóteses**
   - Execução dos 4 testes principais (seção 4)
   - Documentação de resultados (p-valores, estatísticas de teste)
   - Interpretação para contexto de gestão de riscoarxiv+2
1. **Dashboard interativo**
   - Criação em Streamlit ou similar
   - Filtros por aplicação, região, período
   - Visualizações dinâmicas de KPIs de riscomohamadrazzimy.hashnode

Entregáveis:
- Notebook com análises estatísticas completas
- Relatório de testes de hipóteses com interpretação
- Dashboard funcional
- Apresentação visual dos principais achados

Fase 3 – Modelos Preditivos e REST API (Semanas 5-6)

Atividades:
1. **Desenvolvimento de modelos ML**
   - Preparação de features e targets
   - Divisão treino/teste (80/20) com validação cruzada
   - Treinamento de Random Forest, XGBoost, Regressão Logística
   - Avaliação e seleção do melhor modelo
   - Interpretação de feature importancegithub+1
1. **Construção da API RESTful**
   - Implementação em Flask ou FastAPI
   - Conexão com banco SQLite
   - Endpoints principais:
     - GET /incidents – listar incidentes (com filtros por aplicação, severidade, data)
     - GET /incidents/{id} – detalhes de incidente específico
     - GET /stats/by_application – estatísticas por tipo de aplicação
     - GET /stats/by_region – estatísticas por região
     - GET /stats/losses – análise de perdas financeiras
     - POST /predict/severity – predição de severidade via modelo ML
     - POST /predict/loss – estimativa de perda financeira via modelo ML1_Briefing.pdf
   - Documentação automática (Swagger/OpenAPI)
   - Testes de endpoints
1. **Casos de uso e demonstração**

- Exemplos de consultas via API
- Cenários de uso para gestores de risco
- Integração hipotética com sistemas de risk managementoxfordeconomics

Entregáveis:
- Notebooks com modelos treinados e avaliados
- Código-fonte da API RESTful (repositório GitHub)
- Documentação da API (Swagger + README)
- Vídeo ou slides demonstrando uso da API
- Relatório final integrando todas as fases

7. Alinhamento com o Briefing da Disciplina

Este projeto atende plenamente aos requisitos estabelecidos no briefing:

Subprojeto 1 – Consumo de APIs/Dados de Terceiros:
- Uso dos dados do AI Incident Database (AIID) disponíveis via Kaggle e API oficialincidentdatabase+1
- Processamento e integração de dados externos em banco SQL relacional1_Briefing.pdf

Subprojeto 2 – Desenvolvimento de API RESTful:
- Criação de API própria em Flask/FastAPI
- Exposição de dados de banco SQL com ≥3 tabelas relacionadas
- Múltiplos endpoints para consulta, análise e predição1_Briefing.pdf

Requisitos de Dados:
- Banco relacional SQLite com 3+ tabelas inter-relacionadas
- Variáveis quantitativas (perdas financeiras, contagens) e qualitativas (tipos, segmentos)
- Dataset com volume adequado para análises estatísticas robustas e MLkaggle+1

Componentes de Análise:
- Estatística descritiva e inferencial (testes de hipóteses)
- Modelos de IA/ML supervisionados (classificação e regressão)
- Visualizações e dashboard interativo
- Aplicação prática para gestão de risco e governança no setor financeirosciencedirect+1

8. Conclusão e Próximos Passos

Este relatório exploratório estabelece as bases sólidas para o desenvolvimento do projeto piloto focado no setor financeiro. As variáveis selecionadas, as hipóteses formuladas e as técnicas estatísticas/ML planejadas estão alinhadas com os objetivos de investigar viés algorítmico, risco operacional e governança de IA em bancos e fintechs, apoiando decisões informadas de gestores de risco e reguladores.intuition+2

Próximos passos imediatos:
1. Iniciar implementação do código no Google Colab
2. Download e carga do dataset AIID do Kaggle
3. Exploração inicial focada em incidentes do setor financeiro
4. Validação da viabilidade do filtro temático
5. Criação das primeiras variáveis derivadas específicas para finanças
6. Estabelecimento do banco SQLite com esquema inicial

A execução seguirá as 3 fases descritas, com entregas incrementais e documentação contínua, garantindo rastreabilidade e reprodutibilidade de todos os processos.

Título do Projeto:
Análise de Incidentes de IA em Serviços Financeiros: Viés Algorítmico, Risco Operacional e Respostas de Governança em Bancos e Fintechs

Aluna: Fab
Disciplina: [Nome da disciplina]
Instituição: PUC-SP
Data: Março de 2026

PLANO DE NEGÓCIO USANDO CRISP-DM
Metodologia CRISP-DM Aplicada ao Projeto de Análise de Incidentes de IA em Serviços Financeiros

O que é CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) é uma metodologia amplamente reconhecida para projetos de ciência de dados e mineração de dados. Ela organiza o trabalho em 6 fases cíclicas e iterativas, garantindo que o projeto seja orientado por objetivos de negócio e entregue valor prático.
As 6 fases são:

1. **Business Understanding** (Compreensão do Negócio)
2. **Data Understanding** (Compreensão dos Dados)
3. **Data Preparation** (Preparação dos Dados)
4. **Modeling** (Modelagem)
5. **Evaluation** (Avaliação)
6. **Deployment** (Implantação)

Fase 1: Business Understanding (Compreensão do Negócio)

1.1 Objetivos de Negócio

Contexto:
O setor financeiro está adotando rapidamente sistemas de IA para credit scoring, detecção de fraude, trading algorítmico e automação de processos. No entanto, incidentes envolvendo viés algorítmico, falhas operacionais e violações regulatórias têm gerado perdas financeiras significativas, danos reputacionais e sanções regulatórias.intuition+2
Stakeholders principais:

- **Bancos e Fintechs:** necessitam identificar e mitigar riscos operacionais de IA
- **Reguladores financeiros:** precisam supervisionar uso responsável de IA e prevenir discriminação algorítmica
- **Gestores de risco:** requerem ferramentas para avaliar exposição a incidentes de IA
- **Investidores e analistas:** buscam entender impacto de incidentes de IA no valor de instituições financeirasideas.repec+1

Objetivos de negócio:

1. **Reduzir risco operacional:** Identificar padrões de incidentes para prevenir ocorrências futuras
2. **Aumentar conformidade regulatória:** Detectar viés algorítmico e garantir fair lending
3. **Otimizar governança de IA:** Priorizar investimentos em controles internos baseados em evidências
4. **Melhorar tomada de decisão:** Fornecer dados quantitativos para decisões de gestão de risco
5. **Demonstrar responsabilidade:** Comunicar transparência no uso de IA a stakeholders

1.2 Avaliação da Situação

Recursos disponíveis:

- **Dados:** AI Incident Database (AIID) via Kaggle, com milhares de incidentes documentadosincidentdatabase+1
- **Infraestrutura:** Google Colab (gratuito), Python/pandas, SQLite
- **Conhecimento:** Literatura acadêmica sobre viés em IA, regulações financeiras (Basel, GDPR, MiCA, AI Act)fsb+1

Riscos e premissas:
- **Risco:** Dados podem ter viés de reportagem (incidentes em países desenvolvidos mais documentados)
- **Risco:** Perdas financeiras nem sempre reportadas publicamente
- **Premissa:** Incidentes documentados no AIID são representativos de padrões mais amplos
- **Premissa:** Variáveis derivadas capturam adequadamente o contexto financeiro

1.3 Objetivos de Data Mining

Tradução dos objetivos de negócio em objetivos técnicos:
1. **Classificação:** Prever severidade de incidentes (severity_level) com acurácia >75%
2. **Regressão:** Estimar perdas financeiras (financial_loss_amount) com RMSE aceitável
3. **Análise descritiva:** Identificar top 5 aplicações de IA com mais incidentes
4. **Teste de hipóteses:** Provar estatisticamente viés por segmento de cliente ($p<0.05$)
5. **Clustering:** Identificar 4-6 tipologias distintas de risco operacional de IA

1.4 Plano do Projeto

Cronograma (6 semanas):

Fase	Semanas	Entregáveis
Business Understanding	0.5	Este documento, aprovação de stakeholders
Data Understanding	1	Relatório exploratório, perfil de dados
Data Preparation	1	Dataset limpo, banco SQLite populado
Modeling	2	Modelos treinados, métricas de performance
Evaluation	1	Validação de modelos, testes de hipóteses
Deployment	0.5	API RESTful funcional, documentação

Fase 2: Data Understanding (Compreensão dos Dados)

2.1 Coleta de Dados Iniciais

Fonte primária: AI Incident Database (AIID)

Método de acesso:
- Download CSV via Kaggle: https://www.kaggle.com/datasets/konradb/ai-incident-database
- Alternativa: API do AIID (https://incidentdatabase.ai/api-spec/)

Volume esperado:
- Dataset completo: ~2000-3000 incidentes (estimativa 2026)
- Após filtro para setor financeiro: ~200-400 incidentesoxfordeconomics
-

2.2 Descrição dos Dados

Colunas principais esperadas:

Coluna	Tipo	Descrição	Taxa de preenchimento esperada
incident_id	int	ID único	100%
title	str	Título do incidente	100%
summary	str	Resumo descritivo	>90%
occurred_date	date	Data de ocorrência	>80%
country	str	País	>70%
sector	str	Setor (filtrar 'finance')	>60%
technology	str	Tipo de tecnologia	>50%
harm_type	str	Tipo de dano	>60%
severity	str/int	Nível de severidade	>40%

2.3 Exploração dos Dados

Questões exploratórias iniciais:
1. Quantos incidentes estão categorizados como setor financeiro?
2. Qual a distribuição temporal? (tendência crescente/decrescente?)
3. Quais países/regiões concentram mais incidentes?
4. Há valores ausentes significativos em variáveis-chave?
5. Texto de summary permite extração de aplicação (credit, fraud, trading)?

Técnicas de exploração:
- df.info(), df.describe() – visão geral
- df['sector'].value_counts() – contagem por setor
- df.groupby('year').size() – tendência temporal
- Nuvem de palavras de summary para termos financeiros
- Análise de missing data (df.isnull().sum())

2.4 Verificação da Qualidade dos Dados

Critérios de qualidade:
- **Completude:** % de valores preenchidos em colunas críticas
- **Consistência:** formatos de data padronizados, nomes de países uniformes
- **Acurácia:** cross-check de amostra de incidentes com fontes originais
- **Relevância:** incidentes realmente do setor financeiro (evitar falsos positivos no filtro)

Ações corretivas planejadas:
- Imputação de datas faltantes baseada em texto de summary

- Padronização de nomes de países (EUA/USA/United States → USA)
- Remoção de duplicatas (mesmo incidente reportado múltiplas vezes)
- Validação manual de amostra de 20-30 incidentes filtrados

Fase 3: Data Preparation (Preparação dos Dados)

3.1 Seleção de Dados

Critério de inclusão:
- sector contém 'finance', 'banking', 'financial services', 'fintech'
- OU summary/title contém palavras-chave financeiras (credit, loan, trading, fraud detection, etc.)
-

Critério de exclusão:
- Incidentes sem data (impossível análise temporal)
- Duplicatas (mesmo incident_id)
- Descrição muito vaga/sem detalhes suficientes para classificação

Dataset resultante esperado: 200-400 incidentes de alta qualidade

3.2 Limpeza de Dados

Tarefas de limpeza:

1. **Padronização de datas:**
   - Converter occurred_date para formato datetime
   - Extrair year, month, quarter
1. **Padronização de categorias:**
   - Uniformizar country (usando biblioteca pycountry ou mapeamento manual)
   - Normalizar sector (todas as variações → 'finance')
1. **Tratamento de valores ausentes:**
   - country: preencher com 'Unknown' se <5% faltantes, ou tentar extrair de summary
   - severity: manter como ausente, criar variável severity_reported (0/1)
1. **Remoção de outliers:**
   - Verificar datas impossíveis (futuro ou muito antigas sem sentido)
   - Perdas financeiras irrealistas (verificar ordens de magnitude)

3.3 Construção de Variáveis Derivadas

Variáveis categóricas:

- **application_type:** regex/keywords sobre summary
  - "credit scor", "loan approv" → credit_scoring
  - "fraud detect", "AML", "money launder" → fraud_detection
  - "trading", "high-frequency", "algo" → algorithmic_trading
  - "robo-advis", "investment" → robo_advisor
  - etc.
  -
- **customer_segment:** inferência de summary
  - "small business", "SME" → sme
  - "retail", "consumer" → retail
  - "underserved", "minority" → underserved
  - padrão → general
- **incident_type:**
  - "bias", "discriminat", "unfair" → algorithmic_bias
  - "failure", "outage", "crash" → operational_failure
  - "flash crash", "market", "volatilit" → market_disruption

  - "breach", "leak" → data_breach
  - "regulat", "violation", "fine" → regulatory_violation
- **severity_level:** baseado em severity original + keywords
  - Menção de "$XXM" → mapear para escala baixa/média/alta/crítica
  - "bankrupt", "systemic" → crítica
  - "investigation", "fine" → alta
  - "complaint" → média
  - "detected in testing" → baixa

Variáveis numéricas:

- **financial_loss_amount:** regex para extrair valores monetários de summary
  - Padrões: "$10 million", "£5M", "€2.5B"
  - Converter para USD usando taxas de câmbio históricas se necessário
- **year:** extraído de occurred_date

Variáveis geográficas:

- **country_region:** mapeamento de country para regiões
  - USA, Canada → North America
  - UK, Germany, France, etc. → Europe
  - China, Japan, Singapore → Asia-Pacific
  - Brazil, Mexico → Latin America
- **regulatory_regime:**
  - USA → US (SEC, FED)
  - EU countries → EU (GDPR, MiCA, AI Act)
  - UK → UK (FCA)
  - Brazil → BR (BACEN)

Variáveis binárias de governança:

- **regulatory_investigation:** summary contém "investigation", "SEC", "regulator"
- **fine_imposed:** "fine", "penalty", "sanction"
- **policy_change:** "suspend", "halt", "discontinue", "policy change"
- **third_party_audit:** "audit", "third-party review"

3.4 Integração de Dados

Estrutura do banco SQLite:

Tabela incidents (principal):

```sql
CREATE TABLE incidents (
    incident_id INTEGER PRIMARY KEY,
    title TEXT,
    summary TEXT,
    occurred_date DATE,
    year INTEGER,
    country TEXT,
    country_region TEXT,
    regulatory_regime TEXT,
    sector TEXT,
    technology TEXT,
    harm_type TEXT,
    application_type TEXT,
    customer_segment TEXT,
    incident_type TEXT,
```

```
    severity_level TEXT,
    severity_reported INTEGER
);
```

Tabela financial_impacts:

```sql
CREATE TABLE financial_impacts (
    impact_id INTEGER PRIMARY KEY AUTOINCREMENT,
    incident_id INTEGER,
    financial_loss_amount REAL,
    currency TEXT,
    loss_category TEXT, -- direct, indirect, reputational
    FOREIGN KEY (incident_id) REFERENCES incidents(incident_id)
);
```

Tabela regulatory_responses:

```sql
CREATE TABLE regulatory_responses (
    response_id INTEGER PRIMARY KEY AUTOINCREMENT,
    incident_id INTEGER,
    regulatory_investigation INTEGER,
    fine_imposed INTEGER,
    fine_amount REAL,
    policy_change INTEGER,
    system_suspended INTEGER,
    third_party_audit INTEGER,
    FOREIGN KEY (incident_id) REFERENCES incidents(incident_id)
);
```

3.5 Formatação de Dados

Para análises estatísticas:
- Exportar views como CSV para uso em notebooks Jupyter/Colab

Para modelos de ML:
- One-hot encoding de variáveis categóricas (application_type, customer_segment, etc.)
- Normalização de financial_loss_amount (log transform devido a distribuição assimétrica)
- Criação de matriz de features (X) e targets (y_severity, y_loss)

Fase 4: Modeling (Modelagem)

4.1 Seleção de Técnicas de Modelagem

Modelos de classificação (severidade):

1. **Random Forest Classifier**
   - Hipótese: Relações não-lineares entre features

- Hiperparâmetros a tunar: n_estimators, max_depth, min_samples_split

1. **XGBoost Classifier**
   - Hipótese: Melhor performance em dados tabulares
   - Hiperparâmetros: learning_rate, max_depth, n_estimators
1. **Logistic Regression** (baseline)
   - Para severidade binária (baixa/média vs. alta/crítica)
   - Vantagem: interpretabilidade

Modelos de regressão (perda financeira):

1. **Random Forest Regressor**
2. **XGBoost Regressor**
3. **Linear Regression** (baseline)

Técnicas estatísticas:

- Chi-quadrado para testes de hipóteses categóricas
- ANOVA para comparação de médias entre grupos
- Regressão linear para tendência temporal

4.2 Design de Teste

Divisão de dados:

- **Training set:** 80% dos dados (stratified por severity_level)
- **Test set:** 20% dos dados
- **Validação cruzada:** 5-fold CV no training set

Métricas de avaliação:

Para classificação:

- Accuracy
- Precision, Recall, F1-score (macro average)
- ROC-AUC (multiclasse: one-vs-rest)
- Matriz de confusão

Para regressão:

- RMSE (Root Mean Squared Error)
- MAE (Mean Absolute Error)
- R^2 (coeficiente de determinação)
- MAPE (Mean Absolute Percentage Error) se aplicável

Critérios de sucesso:

- Classificação de severidade: F1-score > 0.70
- Regressão de perda: $R^2 > 0.60$ ou RMSE aceitável vs. variância dos dados

4.3 Construção de Modelos

Pipeline típico:

```python
# Exemplo Random Forest Classifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV

# Hiperparâmetros
param_grid = {
    'n_estimators': [100, 200, 300],
    'max_depth': [10, 20, None],
    'min_samples_split': [2, 5, 10]
}

# Model
```

```
rf = RandomForestClassifier(random_state=42)

# Grid search com CV
grid_search = GridSearchCV(rf, param_grid, cv=5, scoring='f1_macro')
grid_search.fit(X_train, y_train)

# Melhor modelo
best_rf = grid_search.best_estimator_
```

Iterações planejadas:
1. Baseline com configurações padrão
2. Tunagem de hiperparâmetros via Grid Search
3. Feature engineering adicional se performance insatisfatória
4. Ensemble de múltiplos modelos se necessário

4.4 Avaliação dos Modelos

Avaliação no test set:
- Aplicar modelos treinados
- Calcular todas as métricas definidas
- Comparar performance entre modelos

Interpretabilidade:
- Feature importance (Random Forest, XGBoost)
- Coeficientes (Logistic Regression, Linear Regression)
- SHAP values para explicar predições individuais

Exemplos de insights esperados:
- "application_type=credit_scoring é o feature mais importante para severidade alta"
- "Incidentes em regulatory_regime=EU têm perdas financeiras 30% menores em média (devido a GDPR)"

Fase 5: Evaluation (Avaliação)

5.1 Avaliação dos Resultados

Critérios de avaliação de negócio:

1. **Modelos atendem objetivos técnicos?**
   - F1-score de severidade atingiu >0.70?
   - R^2 de perda financeira atingiu >0.60?
1. **Insights são acionáveis?**
   - Identificamos aplicações de alto risco?
   - Provamos estatisticamente viés por segmento?
   - Gestores de risco podem usar as predições para priorização?
1. **Hipóteses de negócio foram confirmadas/refutadas?**
   - Há concentração de incidentes em credit scoring? (sim/não com p-value)
   - SMEs são mais afetados por viés? (sim/não com p-value)
   - Severidade alta leva a mais investigações regulatórias? (correlação significativa?)

Validação com stakeholders:
- Apresentar top findings para gestores de risco hipotéticos
- Validar se tipologia de risco faz sentido prático
- Ajustar granularidade de categorias se necessário

5.2 Revisão do Processo

O que funcionou bem:
- Dataset AIID forneceu dados suficientes e relevantes
- Variáveis derivadas capturaram contexto financeiro adequadamente
- Modelos de ML atingiram performance aceitável

O que poderia melhorar:
- Perdas financeiras têm muitos valores faltantes (limita modelo de regressão)
- Viés de reportagem (mais incidentes de países desenvolvidos)
- Necessidade de validação manual de categorização de aplicação

Lições aprendidas:
- Criação de variáveis derivadas requer conhecimento de domínio (finanças + IA)
- NLP leve (keywords) funcionou razoavelmente, mas modelos de linguagem mais sofisticados melhorariam
- SQLite adequado para projeto piloto, mas produção requer PostgreSQL/MySQL

5.3 Determinação dos Próximos Passos

Decisão: Proceder para Deployment?

SIM, se:
- Modelos atendem critérios de performance
- Stakeholders validaram utilidade dos insights
- API RESTful agrega valor (permite consultas dinâmicas)

Ajustes antes de deployment:
- Retreinar modelos com dataset completo (treino+teste) para maximizar performance
- Documentar limitações e premissas claramente
- Preparar guia de uso da API

Fase 6: Deployment (Implantação)

6.1 Planejamento da Implantação

Forma de deployment:
- **API RESTful** em Flask/FastAPI hospedada localmente (para projeto acadêmico)
- Alternativa futura: deploy em nuvem (Heroku, Google Cloud Run, AWS Lambda)

Funcionalidades da API:

1. **Consulta de dados históricos:**
   - GET /incidents?application=credit_scoring&severity=high
   - GET /incidents/{id}
   - GET /stats/by_application
   - GET /stats/by_region
1. **Predições em tempo real:**
   - POST /predict/severity (recebe features, retorna severidade predita)
   - POST /predict/loss (recebe features, retorna perda estimada)
1. **Análises agregadas:**
   - GET /stats/losses (distribuição de perdas por categoria)
   - GET /trends/temporal (série temporal de incidentes)

Documentação:
- Swagger UI automático (FastAPI) ou swagger.json (Flask)
- README com exemplos de uso
- Jupyter notebook tutorial

6.2 Planejamento de Manutenção e Monitoramento

Para projeto acadêmico (escopo limitado):
- Versionamento de código no GitHub
- Documentação de dependências (requirements.txt)

- Instruções de reprodução

Para produção futura:

- **Monitoramento de performance:** log de latência de API, taxa de erro
- **Retreinamento periódico:** atualizar modelos trimestralmente com novos incidentes do AIID
- **Drift detection:** monitorar se distribuição de features muda ao longo do tempo
- **Feedback loop:** capturar feedback de usuários sobre qualidade de predições

6.3 Produção do Relatório Final

Estrutura do relatório final:

1. **Executive Summary**
   - Principais achados (top 3-5 insights)
   - Recomendações para gestores de risco
   -
1. **Metodologia (CRISP-DM)**
   - Resumo de cada fase
   - Decisões tomadas e justificativas
1. **Análise de Dados**
   - Estatísticas descritivas
   - Visualizações principais
   - Resultados de testes de hipóteses
1. **Modelos de ML**
   - Performance de cada modelo
   - Feature importance
   - Exemplos de predições
1. **API RESTful**
   - Documentação de endpoints
   - Exemplos de uso
   - Casos de uso para stakeholders
1. **Conclusões e Trabalhos Futuros**
   - Limitações do estudo
   - Próximos passos (e.g., incorporar dados de mercado acionário, análise de impacto em stock prices)
1. **Anexos**
   - Código (link GitHub)
   - Dicionário de dados completo
   - Tabelas de contingência detalhadas

6.4 Revisão do Projeto

Critérios de sucesso final:

- Banco de dados SQLite funcional com ≥3 tabelas
- Relatório exploratório completo e bem documentado
- Testes de hipóteses executados com interpretação clara
- Pelo menos 2 modelos de ML treinados e avaliados
- API RESTful implementada com ≥5 endpoints funcionais
- Documentação (README, Swagger, notebook tutorial)
- Apresentação final (slides + demo ao vivo)

Critérios de excelência (além do mínimo):

- F1-score de severidade >0.75

- Feature importance gera insights acionáveis
- Dashboard interativo (Streamlit/Plotly Dash)
- Análise de impacto em stock prices de bancos (dados de Yahoo Finance)
- Comparação de regimes regulatórios (US vs. EU vs. Brasil)

Cronograma Detalhado CRISP-DM

Fase	Duração	Semana	Entregáveis Principais
1. Business Understanding	3 dias	Semana 1	Documento de objetivos, aprovação
2. Data Understanding	1 semana	Semana 1	Relatório exploratório, perfil de dados
3. Data Preparation	1 semana	Semana 2	Dataset limpo, banco SQLite, dicionário
4. Modeling	2 semanas	Semanas 3-4	Modelos treinados, métricas, feature importance
5. Evaluation	1 semana	Semana 5	Validação, testes de hipóteses, ajustes
6. Deployment	3 dias	Semana 6	API funcional, documentação, relatório final

Por Que CRISP-DM?

Aplicar CRISP-DM a este projeto garante:

✅ **Alinhamento com negócio:** Cada análise e modelo responde a uma necessidade real de gestão de risco

✅ **Processo estruturado:** Reduz risco de "análise exploratória sem fim" – cada fase tem entregáveis claros

✅ **Iteratividade:** Permite voltar a fases anteriores (ex: se modelo falha, voltar para Data Preparation e criar novas features)

✅ **Comunicabilidade:** Stakeholders entendem a jornada completa do projeto

✅ **Reprodutibilidade:** Documentação de decisões em cada fase permite replicação

ACESSAR DASET E LINKS UTEIS

Os dados foram obtidos a partir do Artificial Intelligence Incident Database (AIID), acessado tanto via download tabular (CSV) disponibilizado no Kaggle (dataset “AI incident database”) quanto pela opção de “Download Complete Database” e pela especificação oficial de API REST no site do AIID.kaggle+3

1. Onde pegar o CSV (dados “baixáveis”)

tem duas opções principais:

- **Kaggle – AI Incident Database (CSV pronto)**
  Link do dataset:
  https://www.kaggle.com/datasets/konradb/ai-incident-databasekaggle No Kaggle você faz:
  - Login na sua conta
  - Clica em “Download” para baixar o .zip com os .csv
  - Depois sobe o CSV para o Colab.
- **Site oficial – Download completo da base**
  Página do AIID:
  https://incidentdatabase.aiincidentdatabase Lá tem opção de **“Download Complete Database”**, que também retorna arquivos em formato tabular (CSV/JSON).verifywise+1

2. API oficial do AI Incident Database

Se você quiser mencionar que existe uma API externa (mesmo que, no piloto, use só o CSV):

- **Especificação da API do AIID (API REST deles):**
  https://incidentdatabase.ai/api-spec/incidentdatabase

Nessa página eles explicam:

- definição de incidente,
- endpoints disponíveis,
- e também indicam como fazer o download completo da base.verifywise+1

```python
import kagglehub

# Download latest version
path = kagglehub.dataset_download("konradb/ai-incident-database")

print("Path to dataset files:", path)
```